주택가격 예측 — 최종 정정 보고서

Ames Housing 회귀 · 원본 → 감사(Audit) → 정정 흐름의 최종본 · 본 PDF는 감사 결과를 반영해 원본 보고서의 과장 · 불일치를 정정한 버전입니다.

0. 정정 요약 (감사에서 발견 · 수정한 4건)

#	원본 서술	정정
1	ElasticNet이 최고/가장 견고한 모델	세 규제 모델은 fold 표준편차 대비 통계적으로 동등. 단순성 · 계수 안정성으로 ElasticNet 선택
2	Total SF가 핵심 가격 요인	제출 모델에 파생변수 부재. 실제 1순위는 입지 · 건물유형(계수 산출)
3	Rare 병합으로 안정성 확보	실제 미적용(dead code). 수정본은 OneHotEncoder(min_frequency)로 구현
4	CV 점수로 일반화 성능 보고	선택=보고의 낙관 편향을 Nested CV로 보완. Private Gap 1%로 외부 검증

1. 최종 결과 (Result)

· Private Test M 0.8708 · 전체 2위 · Train – Test Gap 1.0% (대회 리더보드).

· 누수 제거 후 5 - Fold CV RMSE (재현값):

모델	CV RMSE	fold 표준편차
ElasticNet (α = 0.01, l1 = 0.5)	30,077	± 7,384
Ridge (α = 10)	30,078	± 7,397
Lasso (α = 1.0)	30,259	± 7,013

· 모델 간 평균 차이(약 180) ≪ fold 표준편차(약 7,300) → 세 모델 통계적 동등.

2. 가격 결정 요인 (계수 기반, 정정)

실제 계수 1순위는 입지(Neighborhood: StoneBr · NridgHt 등) > 건물 유형(Bldg Type) > 지상 면적(Gr Liv Area) > 전반 품질(Overall Qual). '어디에 있는가(입지)'의 설명력이 '얼마나 큰가(면적)'보다 컸음. (원본의 'Total SF 최상위' 주장은 해당 변수가 제출 모델에 없던 버그의 산물로 정정.)

3. Audit 정정 내역 (Before → After)

항목	Before	After
파생변수	모델에서 누락	FunctionTransformer로 Pipeline에 반영
희귀범주	dead code	OneHotEncoder(min_frequency = 0.01)
전처리	CV 밖 fit (누수)	Pipeline/ColumnTransformer 내부 fit
성능 보고	그리드 최솟값(낙관)	Nested CV + held - out
변수중요도	근거 코드 없음	계수 직접 산출
재현성	비멱등	멱등 (Run - All 안정)

4. 재현성

원본 CV RMSE 30,129.947을 소수점까지 재현, 저장 모델 reload 예측 일치 확인. 누수 없는 대표 노트북은 Run - All로 동일 결과 산출. 상세 근거: audit_report.md · results/cv_results.csv · results/leaderboard_result.png.

본 정정 보고서의 모든 수치는 실제 데이터로 재현 · 검증됨. 데이터셋: Ames Housing (De Cock, 2011). 원본 보고서는 reports/original_report.pdf, 상세 감사는 audit/audit_report.md 참조.