가천대학교
Gachon University

데이터 마이닝과 분석 8조

수치형 변수를 이용한
회귀 예측 모델 구축

김지우, 박새하, 오지원, 홍선빈

Index

목차

Chapter 1. **프로젝트 개요**
- 문제 정의
- 목표 설정

Chapter 2. **데이터 이해**
- 구조 및 기초 통계
- EDA
- 품질 진단

Chapter 3. **데이터 전처리**
- 결측치 처리
- 인코딩 및 스케일링
- 파생변수 생성

Chapter 4. **모델링 및 성능 평가**
- 모델 선정
- 파라미터 튜닝

Chapter 5. **모델 평가 및 해석**
-성능 평가 및 최종 기법

프로젝트 개요

문제 정의 및 목표 설정

- 주택 가격은 다양한 요인이 복합적으로 작용하므로, 데이터 기반의 객관적 평가 모델 필요
- Ames Housing 데이터를 활용하여 가격 결정 요인을 분석하고, 신뢰도 높은 회귀 예측 모델을 구축하고자 함

정확한 가격 예측

- 실재 거래 가격과의 오차를 최소화

가격 결정 요인 해석

- 가격 변동에 영향을 미치는 주요 변수 파악 및 해석

일반화된 모델 확보

- 과적합을 방지하여 새로운 데이터에도 안정적인 모델 개발

데이터 이해

데이터 구조 및 기초 통계

- 2,344개의 관측치, 기초 통계량(평균, 표준편차 등) 확인함

종속변수

SalePrice

독립변수

수치형 변수-16개

종속변수인 SalePrice,
Overall Qual, Gr Live Area등 13개

범주형 변수-15개

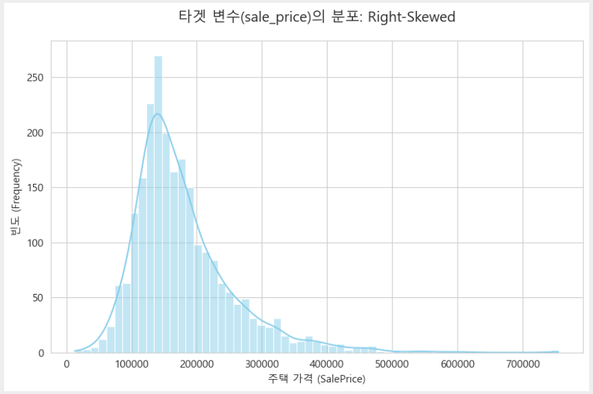
Neighborhood, Fireplace Qu 등 13개

데이터 이해

EDA

타켓 변수 분석

SalePrice의 분포

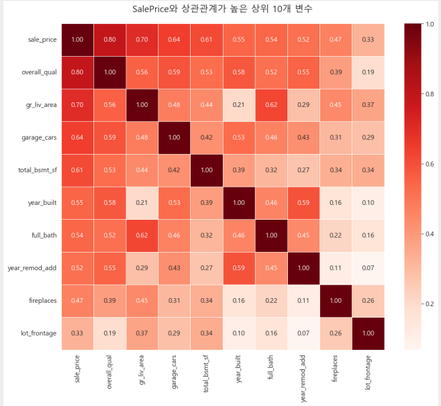


양의 왜도

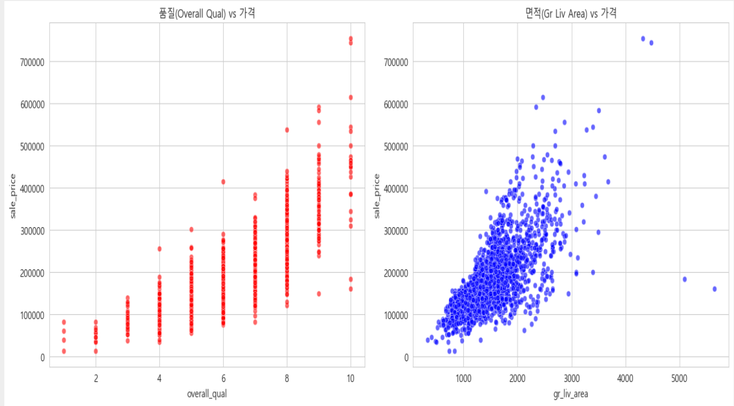
고가 주택이 예측 성능을 떨어뜨릴 수 있기에
모델 학습 시 로그 변환고려 필요

주요 상관관계 분석

SalePrice와 상관관계가 높은 6개 변수



Overall Qual / Gr Live Area- 가격



- Overall Qual과 0.8의 강한 상관성

Overall Qual · Gr Live Area, 높은 양의 상관관계

집값(SalePrice)은 '품질'과 '크기'의 영향력을 데이터로 검증하였으며,
이는 향후 모델링에서 가장 중요한 예측 변수로 작용할 것

데이터 이해

EDA

범주형 변수 분석

- 목표:
  범주 수가 많은 변수 확인 및 **희귀 카테고리(<1%)탐색**

- 목적:
  1. 원-핫 인코딩 적용 시 발생할 수 있는 **컬럼 수 폭발 가능성** 사전 확인
  2. **Rare category 병합** 여부 판단
  3. 전체 전처리 설계의 단순화와 안정성 확보

- 의의: 범주형 변수 EDA 절차를 수행함

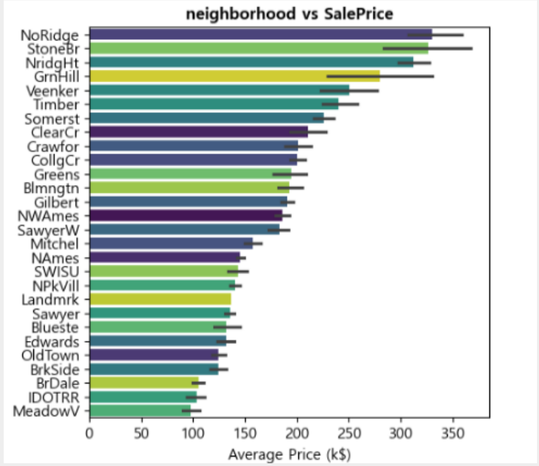
▼

희귀 카테고리(비율 < 1%) 많은 변수 TOP 2

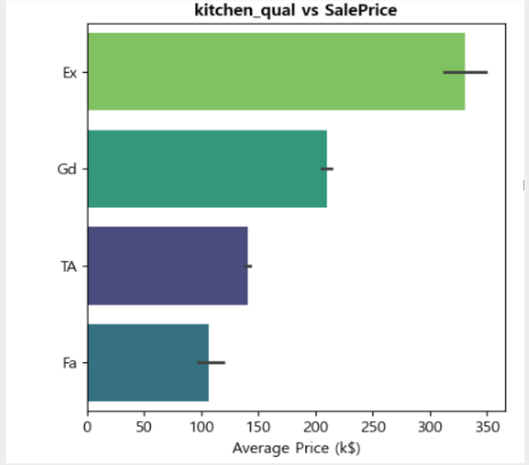
ms_zoning : 3개
garage_type : 2개

범주형 변수 VS 타겟 관계 분석

- Neighborhood의 집단 간 변별력 확인



- KitchenGual 의 뚜렷한 순서성



▼

'Boxplot'을 통해 범주별 중앙값의 차이와 데이터 분포의 비교

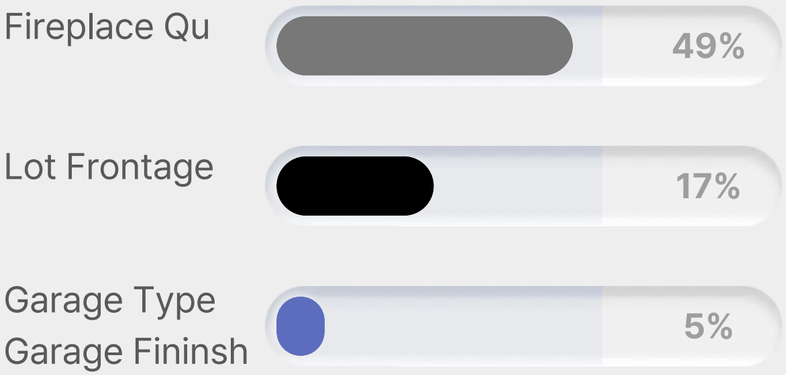
[**순서가 있는 범주**] 위쪽에 위치한 카테고리일수록 평균 집값이 높음
[**편차**] 막대 끝의 검은 선(신뢰구간)이 짧을수록 가격이 평균 근처에 밀집해 있다는 뜻임

데이터 이해

품질 진단

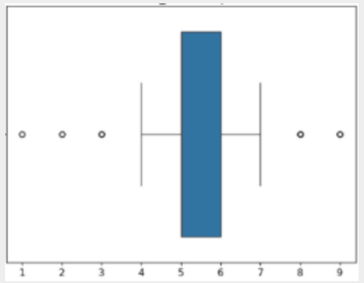
- 데이터의 결측치 및 이상치를 파악하여, 삭제 여부와 모델링 전략을 수립

결측치



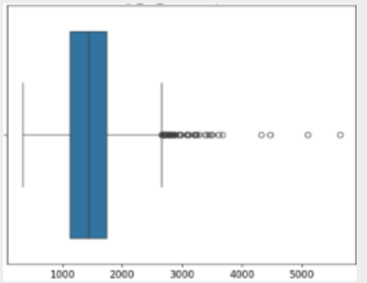
이상치

Overall Cond 8%



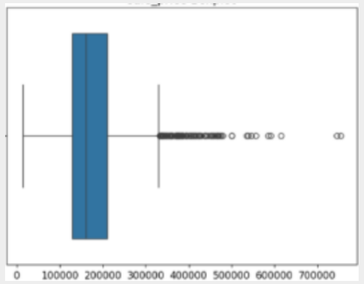
- 이상치로서의 의미X

Gr Live Area 3%



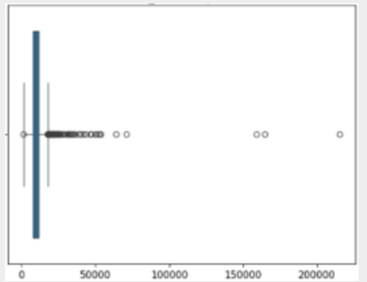
- 종속변수에 강한 영향을 끼치는 변수

SalePrice 5%



- 양의 왜도

Lot Area 5%



- 평균값과 스케일 차이가 큼

대부분 변수는 결측이 거의 없으며 Fireplace Qu · Lot Frontage만 의미 있는 결측 처리 대상으로 확인됨
또한 일부 극단값이 있으나 비율이 낮아 제거하지 않았으며, 고가·대형 주택의 특성을 고려해 Elastic Net(규제 모델)으로 이상치 영향만 완충하는 방향이 고려됨

데이터 전처리

구조적 결측 처리

- df['Column_Name'] = df['Column_Name'].fillna(Value_to_Fill)
- **None = "존재하지 않음"**, 수치형은 **'0'**으로, 범주형은 **'별도의 범주'**로 대치

49%	01	**Fireplcae Qu**	[범주형] 구조적 결측	**"None"**	"벽난로 없는 집" 특성 보존
5%	02	**Garage Type, Garage Finish**	[범주형] 구조적 결측	**"None"**	• "차고 없는 집" • "garage_type_None" 더미생성
3%	03	**BaseMent 관련 변수**	[범주형] 품질 측정 불가	**"NoBaseMent"**	결측을 하나의 특성으로
0.1%	04	**Garage Cars, Total Bsmt Sf**	[수치형] 시설 없음 = 용량 · 면적 '0'	**"0"**	평균값 대치 시 논리적 모순 → '0' 대치하여 일관성 확보

데이터 전처리

비구조적 결측 처리

None = "**실제 값의 유실**", Lot Frontage는 '**동네별 중앙값**'으로, 일반 수치형은 '**중앙값**'으로, 범주형은 '**최빈값**'으로 대치

Lot Frontage

집 자체 특성보다
'동네 도로 특성'에 영향을 받는 변수

전체 중앙값 대치는 동네별 도로 특성을 무시해 왜곡 발생

Neighborhood별 중앙값

- .groupby('neighborhood')['lot_frontage'].median()

- 전체 중앙값으로 인한 왜곡 방지
- 해당 지역의 특성 보존

수치형 변수

Lot Frontage를 제외한 모든 수치형 변수

중앙값 / .median()

분포 왜곡 방지

범주형 변수

- MS Zoning: 모든 주택의 행정 구역 분류 반드시 존재
- KitchenQual: 주방이 없는 주택은 존재X

최빈값 / .mode()[0]

이상치 영향 완화

데이터 전처리

데이터 누수 방지

학습(Fit) + 적용(Transform)

"Train 데이터로만 결측치를 채워, Test 데이터를 보지 않고, 가장 안전한 예측임."

Train 데이터에서만
중앙값/최빈값을 계산

계산된 'Train의 값'을
Train, Test 데이터에 동일하게 대입

데이터 전처리

인코딩 전처리

정의

인코딩 수행 전, 데이터 분포를 고려하여 범주를 재구성

[전략] 회귀 범주 병합

분포 비율이 1% 미만인 극소수 범주, 모델 학습 시 노이즈로 작용하거나 과적합을 유발할 수 있음

- **원-핫 인코딩 차원 폭팔 방지**
- **교차검증 안정화**
- **과적합 방지**
- **해석 가능성 향상**

희소 값들을 'Rare'라는 하나의 범주로 통합하여 모델의 안정성을 확보함

데이터 전처리

범주형 변수 인코딩

변수 특성에 따라 **순서형**은 서열 정보를 보존해 **선형성**을 강화하고, **명목형**은 **차원 적합성**을 확보해 학습 안정성을 높임

순서형 변수

대상

- Kitchen Qual, Exter Qual 등 **순서가 명확한 변수**

기법

- **서열 인코딩**: 품질 수준이 높아질수록 큰 값 부여
  - 매핑 기준: Ex(5) > Gd(4) > · · · > Po(1)

전략

- 품질과 가격의 **양의 상관관계를 학습**시키기 위해 **등급에 비례하는 점수** 부여

의의

- **모델이 '품질-가격의 비례 관계'를 학습하도록 돕고, 차원 축소를 통해 다중공선성 문제 최소화**

명목형 변수

대상

- Neighborhood, BldgType 등 **순서가 없는 변수**

기법

- **원-핫 인코딩**: 범주를 0과 1의 벡터로 변환
  ['A' → 1 0 0], ['B' → 0 1 0]

전략

- **다중공선성** 및 Train/Test 데이터 간 **차원 불일치 문제** 해결

의의

- **범주 간 독립성을 보장**하여 잘못된 서열 학습을 막고, **규제 모델로 제어**함

데이터 전처리

명목형 변수 처리 전략

* pd.get_dummies() / 선형 모델이 학습 가능한 0과 1의 더미 변수로 변환 *

핵심 논리

- 유추 가능한 첫 번째 범주를 제거

- Train 데이터의 틀에 맞춰
  Test 데이터의 컬럼 구성을 똑같이 맞춤

구현 코드

- pd.get_dummies(**drop_first=True**)

- **align**(join='left', axis=1, fill_value=0)

✓ 불필요한 변수 제거로 다중공선성 문제 최소화

✓ Train-Test 차원 불일치 문제 사전 제거

데이터 전처리

분포 교정

규제 모델 도입 계획 | **표준화 적용** | **교차 검증 적용**

Lasso/Ridge/ElasticNet

- 계수에 페널티를 부여하여 이상치에 대한 민감도를 억제

StandardScaler

: 변수들 간의 스케일을 '**평균 0, 표준편차 1**'로 통일

- scaler. [fit_transform / transform]
  ([train / test])

- 스케일이 큰 변수가 모델의 가중치 학습을 지배하는 것을 방지

K-Fold

: 전체 데이터를 **여러 개의 폴드로** 나누어
학습과 검증을 반복

- KFold(n_splits, shuffle, random_state)

- 단일 검증셋 사용 시 발생할 수 있는 우연성 배제
- 과적합 방지

인위적 삭제(Winsorization)없이, **데이터를 살리되 영향력만 완화**하는 통계적 기법 3가지로 이상치를 제어함

데이터 전처리

파생변수 생성

파생변수

Total SF = Total Bsmt Sf + Gr Liv Area

지상과 지하 면적을 합산하여 주택의 실질적인 전체 규모를 반영

House Age = Yr Sold - Year Bulit

판매 시점 기준의 절대 연식으로 변환하여 건물의 노후화를 반영

과적합 방지를 위한 최소한의 파생변수 생성

도메인 지식에 기반하되, 안정적 변수만 채택

파생변수만 사용 시 성능이 저하되어 기존 변수도 함께 유지함.

모델링

모델 선정 및 파라미터 튜닝

모델 선정

- One가 적용된 데이터 복사 후 사용
- Elastic Net 모델 초기화 후 학습 수행
- 5-Fold 교차검증
- RMSE 성능 평가

파라미터 튜닝

- GridSearchCV 탐색 공간
  - Ridge : alpha = [0.01,0.03,0.1,0.3,10,30]
  - Lasso : alpha = [0.0001, 0.0003, 0.001, 0.003, 0.01, 0.03, 0.1]
  - Elastic Net : alpha = alpha = [0.0001~1.0] l1_ratio = [0.05~0.9]
- cv = KFold(n_splits=5, shuffle=True, random_state=42)
- estimator : enet

✓ 모델이 데이터 규칙 학습 후

✓ Best Params
- alpha = 0.03, L1_ratio = 0.9.
- Best CV RMSE ≈ 30,130

✓ 예측 구조 형성하는 단계

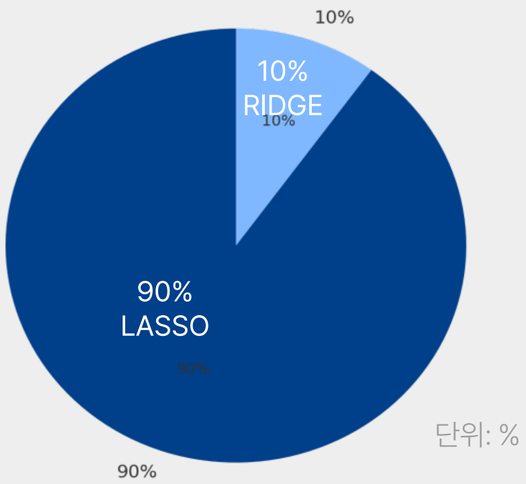
✓ 모델 안정성 확보 &
더 작은 RMSE 기반으로 Best Model 선택

모델링

성능 평가 및 최종 기법 선택

- **Best CV RMSE : 30129.XX**

Elastic Net(비로그) 최종 기법 선택



단위: %

- 선정 이유 : **이중 규제를 통한 모델의 견고성 확보**

즉, L1/L2 규제를 동시에 적용하여 데이터의 이상치와 다중공선성 문제를 한번에 해결, 모델의 견고성 확보함

2위
Ridge

안정적이나 Elastic Net 대비 성능 낮음

- **Best CV RMSE : 30149.XX**

3위
Lasso

변수 선택은 좋으나 성능이 다른 모델에 비해 낮음

- **Best CV RMSE : 30291.XX**

4위
Lasso 선택 + Ridge 안정화

ElasticNet이 이미 L1과 L2 규제를 동시에 포함되어 있고, 성능 평가에서는 가장 낮은 결과를 보임

- **Best CV RMSE : 43504.XX**

지금까지 발표를 들어주셔서 감사합니다.

